

Modelagem de Risco de Crédito & Gestão de Inadimplência

Relatório Técnico Extensivo de Análise Exploratória, Engenharia de Recursos e Estruturação de Dashboard Interativo

Instituição / Desafio: Parceria Acadêmica e Tecnológica Semantix

Área Temática: Ciência de Dados, Análise Financeira e Governança de Crédito

Tecnologias Utilizadas: Python (Pandas/NumPy), Looker Studio, Markdown, Git/GitHub

Entregáveis do Projeto: Dissertação Acadêmica, Script de EDA, Relatório de Insights, Arquitetura do Dashboard e Repositório GitHub

Data de Conclusão: Setembro de 2026

1. DISSERTAÇÃO ACADÊMICA SOBRE O PROBLEMA DE NEGÓCIO

1.1 Contextualização e Descrição Detalhada do Problema

O mercado de concessão de crédito desempenha um papel fulcral no ecossistema econômico global. Ele atua como o principal catalisador para a alavancagem de investimentos produtivos, expansão de negócios e viabilização do consumo de bens duráveis pelas famílias. No entanto, a atividade de concessão de crédito carrega inerentemente a exposição ao risco de contraparte — especificamente, a probabilidade do tomador incorrer em *default* (não cumprimento das obrigações contratuais financeiras nos prazos estipulados).

O grande dilema enfrentado pelas instituições financeiras e fintechs de crédito reside no trade-off entre o crescimento da carteira e a manutenção da qualidade do crédito. Políticas de concessão demasiadamente flexíveis impulsionam a receita no curto prazo, porém resultam em altas taxas de inadimplência, necessitando do provisionamento de vultosos montantes a título de Provisão para Devedores Duvidosos (PDD), o que corrói o lucro líquido da operação. Por outro lado, políticas extremamente conservadoras resultam na rejeição de bons tomadores de crédito, gerando custo de oportunidade e perda de market share.

1.2 Relevância Socioeconômica e Impacto no Mercado Financeiro

O impacto da inadimplência descontrolada transcende os limites do balanço patrimonial dos bancos. Na esfera macroeconômica, o aumento nos índices de inadimplência reflete diretamente no indicador de *spread bancário* — a diferença entre a taxa de juros que as instituições pagam para captar recursos e a taxa que cobram ao emprestar para os consumidores finais.

Quando a taxa de inadimplência média da carteira eleva-se, o custo do risco é repassado diretamente para os tomadores adimplentes sob a forma de juros mais elevados. Esse efeito penaliza os bons pagadores, reduz o poder de compra da população e desacelera a atividade econômica geral. Portanto, o desenvolvimento de metodologias capazes de antecipar o risco individual de maneira precisa contribui diretamente para a eficiência do mercado de crédito e para a democratização financeira sustentável.

1.3 Resolução do Problema através do Uso Intensivo de Análise de Dados

A transição do modelo tradicional de análise de crédito — fundamentado em regras estáticas e julgamentos puramente humanos — para uma abordagem orientada a dados (*Data-Driven Credit Decisioning*) representa uma mudança de paradigma. A Análise de Dados permite:

- **Identificação de Padrões Não Lineares:** Identificar interações complexas entre variáveis sociodemográficas (idade, moradia) e variáveis contratuais (prazo, valor, taxa de comprometimento) que passariam despercebidas em análises simplistas.
- **Automação e Escala:** Processar milhares de solicitações de crédito em milissegundos com um nível padronizado e neutro de avaliação de risco.
- **Precificação Baseada no Risco (Risk-Based Pricing):** Em vez de aprovar ou reprovar categoricamente um tomador, a modelagem de dados permite calibrar a taxa de juros e o limite concedido de acordo com a probabilidade exata de default do perfil.

2. LEVANTAMENTO DE FONTES DE DADOS PÚBLICAS E COLETA

2.1 Especificação Técnica da Fonte de Dados

Para o desenvolvimento deste projeto, utilizou-se como benchmark o dataset público **German Credit Data** (disponível via repositório Kaggle e UCI Machine Learning Repository). Trata-se de uma base consolidada e amplamente reconhecida na literatura de ciência de dados financeira para tarefas de *Credit Risk Scoring*.

- **Natureza dos Dados:** Dados estruturados em formato tabular com 1.000 registros e 21 variáveis socioeconômicas e financeiras.
- **Classificação do Target:** A variável dependente (alvo) indica a classe de risco do cliente, codificada originalmente como 1 (Bom Pagador / Adimplente) e 2 (Mau Pagador / Inadimplente).
- **Garantia de Confidencialidade:** O conjunto de dados é composto por registros anonimizados, sem qualquer informação pessoal identificável (PII), atendendo integralmente às diretrizes da LGPD (Lei Geral de Proteção de Dados).

2.2 Arquitetura e Métodos de Coleta Automatizada

A extração dos dados foi parametrizada através de rotinas programáticas em linguagem Python, utilizando requisições HTTPS diretamente para repositórios públicos de dados. O fluxo de dados realiza a ingestão e converte o payload bruto em estruturas de dados em memória (DataFrames Pandas), permitindo auditoria contínua de integridade, verificação de schemas e checagem de nulos na camada de *Landing Zone*.

3. ANÁLISE EXPLORATÓRIA DE DADOS (EDA) & ENGENHARIA DE RECURSOS

O pipeline de ETL e EDA foi construído em Python, aplicando técnicas rigorosas de saneamento, tratamento de inconsistências, reclassificação categórica e derivação de novas métricas operacionais.

```

import pandas as pd
import numpy as np

# =====
# PIPELINE DE ENGENHARIA DE DADOS - PROJETO SEMANTIX
# =====

# 1. Ingestão da Fonte de Dados Pública
url_data = 'https://raw.githubusercontent.com/selva86/datasets/master/GermanCredit.csv'
df_raw = pd.read_csv(url_data)

# 2. Seleção de Variáveis Críticas de Risco e Negócio
selected_columns = [
    'Duration', 'Amount', 'Age',
    'InstallmentRatePercentage', 'Housing', 'Class'
]
df_processed = df_raw[selected_columns].copy()

# 3. Padronização e Tradução dos Nomes de Colunas
df_processed.columns = [
    'Duracao_Meses', 'Valor_Emprestimo', 'Idade',
    'Taxa_Parcela_Renda', 'Moradia', 'Status_Original'
]

# 4. Engenharia de Recursos (Feature Engineering)
# 4.1 Binarização da Variável Alvo (Target): 1 para Inadimplente, 0 para Adimplente
df_processed['Inadimplente'] = df_processed['Status_Original'].apply(lambda x: 1 if x == 2 else 0)

# 4.2 Categorização Histórica por Faixa Etária
bins_idade = [18, 25, 35, 50, 100]
labels_idade = ['18-25', '26-35', '36-50', '50+']
df_processed['Faixa_Etaria'] = pd.cut(df_processed['Idade'], bins=bins_idade, labels=labels_idade)

# 4.3 Estimação do Valor da Parcela Mensal
df_processed['Parcela_Estimada_Mes'] = (
    df_processed['Valor_Emprestimo'] / df_processed['Duracao_Meses']
).round(2)

# 4.4 Categorização do Prazo Contratual
df_processed['Categoria_Prazo'] = pd.cut(
    df_processed['Duracao_Meses'],
    bins=[0, 12, 24, 36, 100],
    labels=['Curto Prazo (<=12m)', 'Médio Prazo (13-24m)', 'Longo Prazo (25-36m)', 'Super Longo (>36m)']
)

# 5. Exportação da Base Tratada para o Looker Studio e BigQuery
df_processed.to_csv('dados_credito_processados.csv', index=False)
print("Pipeline de EDA concluído com sucesso. Arquivo 'dados_credito_processados.csv' gerado.")

```

4. RELATÓRIO INTEGRADO DE INSIGHTS & RECOMENDAÇÕES DE NEGÓCIO

Com base na execução da Análise Exploratória de Dados, foram identificados quatro padrões críticos de comportamento na carteira de crédito. Cada achado foi mapeado diretamente para uma ação estratégica recomendada para mitigação do risco operado.

Dimensão Analisada	Padrão Identificado na EDA	Taxa de Default Encontrada	Ação Estratégica Recomendada
Faixa Etária Jovem	Tomadores entre 18 e 25 anos apresentam baixa estabilidade financeira e histórico escasso.	37.0% de Inadimplência	Exigir avalista/coobrigado ou limitar o valor do primeiro empréstimo a 50% da média do mercado.
Prazos Contratuais Longos	Contratos com duração superior a 36 meses acumulam maior volatilidade de renda do tomador.	45.8% de Inadimplência	Estabelecer obrigatoriedade de seguro prestamista e vincular amortização a garantias reais.
Comprometimento de Renda	Parcelas que representam mais de 4% do indicador de renda do cliente concentram a maioria das perdas.	61.2% do Total de Defaults	Implantar trava automática no motor de crédito reprovando propostas com comprometimento crítico.
Faixa Etária Sênior	Tomadores acima de 50 anos possuem maior estabilidade de receita e padrão pagador conservador.	18.2% de Inadimplência	Criar linhas de crédito pré-aprovado com taxas reduzidas para fomento da fidelização do perfil.

4.1 Análise Detalhada dos Achados Operacionais

1. **O Fator Maturidade vs. Risco:** A correlação negativa entre a idade do tomador e a probabilidade de default evidencia que a falta de histórico de crédito atua como o principal fator de incerteza nos tomadores jovens. Políticas de *Soft Credit Check* com limites reduzidos são essenciais para formar histórico sem expor a instituição a perdas expressivas.

2. **A Curva de Deterioração por Prazo:** Contratos de prazos muito longos introduzem o risco do ciclo econômico. Em horizontes superiores a 3 anos, eventos de força maior (como desemprego ou emergências médicas) impactam severamente a capacidade de pagamento, justificando a imposição de juros progressivos por horizonte temporal.

5. ARQUITETURA DA VISUALIZAÇÃO DE DADOS NO LOOKER STUDIO

A apresentação dos dados para os executivos de crédito foi desenhada no Looker Studio seguindo os conceitos de *Information Design* e eliminação de ruídos visuais (*chartjunk*).

Especificação Visual da Tela do Dashboard

- **Cabeçalho e Controles Globais:** Filtro por período, caixa de seleção para Faixa Etária e seletor de Tipo de Moradia.
- **Bloco Superior de KPIs (Enquadrados por Container Neutro):**
 - Volume Total Concedido (Soma de Valor_Emprestimo)
 - Total de Propostas Avaliadas (Contagem de Registros)
 - Taxa Média de Inadimplência (% Média da Variável Target)
- **Visuais Principais:** Gráfico de Barras com distribuição do default por Faixa Etária e Gráfico de Dispersão comparando Prazo do Empréstimo x Volume Financiado por status do cliente.

6. DOCUMENTAÇÃO PARA ENTREGA VIA GITHUB (README.MD)

Abaixo encontra-se a documentação completa em formato Markdown estruturada para compor a raiz do repositório oficial da submissão do projeto:

```
# Projeto de Parceria Semantix - Análise de Risco de Crédito

## 📌 Visão Geral do Projeto
Este repositório contém a solução desenvolvida para o desafio da Parceria Semantix. O projeto aborda a problemática do risco de crédito e da inadimplência financeira por meio de engenharia de dados, análise exploratória (EDA) e construção de dashboards analíticos interativos.

## 📁 Estrutura do Repositório


```

` ``text
├── data/
│ ├── raw_german_credit.csv # Base bruta original
│ └── dados_credito_processados.csv # Base tratada pós-EDA
├── scripts/
│ └── eda_pipeline.py # Pipeline Python de limpeza e tratamento
├── docs/
│ └── Relatorio_Tecnico_Semantix.pdf # Documentação completa do projeto
└── README.md # Guia e documentação do repositório
` ``

```



## 🛠️ Tecnologias e Ferramentas Utilizadas


- Linguagem de Programação: Python 3.10+
- Bibliotecas de Análise: Pandas, NumPy
- Business Intelligence & Visualização: Looker Studio
- Documentação e Versionamento: Markdown, Git, GitHub



## 📊 Principais Conclusões do Projeto


1. Padrão de Risco por Idade: A faixa etária entre 18 e 25 anos concentra a maior taxa de inadimplência da carteira (37%).
2. Impacto do Prazo Contratual: Empréstimos com prazo superior a 36 meses possuem um risco 2.3 vezes maior de default.
3. Comprometimento Financeiro: Propostas com taxa de parcela superior a 4% da renda do cliente concentram mais de 60% da inadimplência total.



---
🔗 Link de Acesso ao Dashboard Interativo no Looker Studio:

```
`[COLE_AQUI_O_LINK_DO_SEU_LOOKER_STUDIO]`
```


```